

EmotionLens

Bibliografía científica y procedencia de constantes

Este documento registra el respaldo científico de cada constante numérica que gobierna el comportamiento de EmotionLens, y — con igual detalle — identifica las que no lo tienen. Se genera automáticamente a partir de `backend/app/references.py`, de modo que no puede quedar desactualizado respecto al código.

Cómo leer este documento

Cada constante está clasificada en uno de tres niveles de evidencia. La distinción central es entre **usar un concepto respaldado** y **usar un valor numérico publicado**: el proyecto hace mucho de lo primero y poco de lo segundo, y este documento existe para hacer esa diferencia explícita y auditable.

Nivel	Significado	N.º
VALIDADO	El valor proviene de una fuente publicada y revisada por pares. Se puede citar el número exacto.	7
CALIBRADO	El valor fue ajustado empíricamente sobre un dataset público con codificación FACS certificada, reportando métricas de error.	0
HEURISTICO	No existe evidencia publicada para este valor. Fue elegido por prueba y error y debe presentarse como tal ante el usuario.	20

Estado actual: 20 de 27 grupos de constantes carecen de respaldo publicado. Entre ellas están las que definen la semántica visible del sistema — los pesos del score de congruencia y los cortes verde/amarillo/rojo — es decir, precisamente aquellas cuya salida interpreta un entrevistador humano.

Bibliografía

Base anatómica: FACS

Ekman, P., & Friesen, W. V. (1978). Facial Action Coding System: A Technique for the Measurement of Facial Movement. Consulting Psychologists Press, Palo Alto, CA.
<https://www.paulekman.com/facial-action-coding-system/>

Ekman, P., Friesen, W. V., & Hager, J. C. (2002). Facial Action Coding System: The Manual (2nd ed.). Research Nexus, Salt Lake City, UT. <https://www.paulekman.com/facial-action-coding-system/>

Micro-expresiones: temporalidad

Yan, W.-J., Wu, Q., Liang, J., Chen, Y.-H., & Fu, X. (2013). How Fast are the Leaked Facial Expressions: The Duration of Micro-Expressions. *Journal of Nonverbal Behavior*, 37(4), 217–230. DOI: 10.1007/s10919-013-0159-8

Matsumoto, D., & Hwang, H. C. (2018). Microexpressions Differentiate Truths From Lies About Future Malicious Intent. *Frontiers in Psychology*, 9, 2545. DOI: 10.3389/fpsyg.2018.02545

Datasets con codificación FACS certificada

Yan, W.-J., Li, X., Wang, S.-J., Zhao, G., Liu, Y.-J., Chen, Y.-H., & Fu, X. (2014). CASME II: An Improved Spontaneous Micro-Expression Database and the Baseline Evaluation. *PLoS ONE*, 9(1), e86041. DOI: 10.1371/journal.pone.0086041

Davison, A. K., Lansley, C., Costen, N., Tan, K., & Yap, M. H. (2018). SAMM: A Spontaneous Micro-Facial Movement Dataset. *IEEE Transactions on Affective Computing*, 9(1), 116–129. DOI: 10.1109/TAFFC.2016.2573832

Mavadati, S. M., Mahoor, M. H., Bartlett, K., Trinh, P., & Cohn, J. F. (2013). DISFA: A Spontaneous Facial Action Intensity Database. *IEEE Transactions on Affective Computing*, 4(2), 151–160. DOI: 10.1109/T-AFFC.2013.4

Parpadeo

Bentivoglio, A. R., Bressman, S. B., Cassetta, E., Carretta, D., Tonali, P., & Albanese, A. (1997). Analysis of blink rate patterns in normal subjects. *Movement Disorders*, 12(6), 1028–1034. DOI: 10.1002/mds.870120629

Soukupová, T., & Čech, J. (2016). Real-Time Eye Blink Detection using Facial Landmarks. 21st Computer Vision Winter Workshop, Rimske Toplice, Slovenia. <https://vision.fe.uni-lj.si/cvww2016/proceedings/papers/05.pdf>

Maffei, A., et al. (2025). The eye, a spy hole on human mind: Spontaneous blink rate and amplitude, and their variability, as new psychobiological markers of anxiety. *PLOS ONE*, 20. DOI: 10.1371/journal.pone.0338262

Ritmo cardíaco remoto (rPPG)

de Haan, G., & Jeanne, V. (2013). Robust Pulse Rate from Chrominance-Based rPPG. *IEEE Transactions on Biomedical Engineering*, 60(10), 2878–2886. DOI: 10.1109/TBME.2013.2266196

Wu, H.-Y., Rubinstein, M., Shih, E., Guttag, J., Durand, F., & Freeman, W. T. (2012). Eulerian Video Magnification for Revealing Subtle Changes in the World. *ACM Transactions on Graphics (SIGGRAPH)*, 31(4), 65. DOI: 10.1145/2185520.2185561

Límites de la inferencia facial

- Barrett, L. F., Adolphs, R., Marsella, S., Martinez, A. M., & Pollak, S. D. (2019). Emotional Expressions Reconsidered: Challenges to Inferring Emotion From Human Facial Movements. *Psychological Science in the Public Interest*, 20(1), 1–68. DOI: [10.1177/1529100619832930](https://doi.org/10.1177/1529100619832930)
- Bond, C. F., & DePaulo, B. M. (2006). Accuracy of Deception Judgments. *Personality and Social Psychology Review*, 10(3), 214–234. DOI: [10.1207/s15327957pspr1003_2](https://doi.org/10.1207/s15327957pspr1003_2)
- National Research Council, Committee to Review the Scientific Evidence on the Polygraph (2003). *The Polygraph and Lie Detection*. The National Academies Press, Washington, DC. DOI: [10.17226/10420](https://doi.org/10.17226/10420)

Inventario de constantes

Cada fila vincula una constante del código con su nivel de evidencia y sus fuentes. La columna de notas indica qué respalda exactamente la cita — o, cuando no hay respaldo, por qué.

Constante / Ubicación	Valor	Nivel	Notas y fuentes
micro_expr_min_duration_ms / max_duration_ms config.py:57-58	40 ms / 500 ms	VALIDADO	La literatura sitúa la duración total de una micro-expresión por debajo de 500 ms. La cota inferior de 40 ms es conservadora y compatible. Yan et al. (2013)
Bonificación por duración 'óptima' micro_expressions.py:535	80–200 ms	VALIDADO	Corregido (Fase 1.5): Yan et al. sitúan la moda de duración en 80–200 ms; el código usaba 100–250 ms. Ya coincide con la fuente. Yan et al. (2013)
MICRO_EXPR_PATTERN S (6 prototipos EMFACS) micro_expressions.py:54-97	miedo, ira, asco, tristeza, sorpresa, desprecio	VALIDADO	Corregido (Fase 1.3): se agregó AU5 a miedo/ira/sorpresa y AU1 a sorpresa (EMFACS los incluye y el código los omitía, sesgando esas tres emociones hacia falsos negativos); se agregó AU4 a tristeza; se quitó AU25 de asco (no pertenece a su prototipo EMFACS). Los 6 patrones ahora coinciden con los prototipos publicados. La categoría 'stress' es un componente aparte, ver la entrada siguiente. Ekman et al. (2002)
Patrón 'stress' (no-EMFACS) micro_expressions.py:94-99	AU23+AU24 (req.), AU4+AU7 (sup.)	HEURISTICO	No es un prototipo EMFACS publicado: es invención del proyecto. Se decidió mantenerlo (código externo depende de la etiqueta 'stress') pero marcarlo explícitamente como heurístico en el propio código, en vez de eliminarlo o presentarlo como si tuviera el mismo respaldo que los otros 6.
AU5 (Upper Lid Raiser) action_units.py:249-267	$\text{clip}((\text{ratio} - 0.10) \times 10.0, 0, 1)$	HEURISTICO	Implementado (Fase 1.4): AU5 aparece en 3 de los 6 prototipos EMFACS de emoción básica y antes no se calculaba, sesgando miedo/ira/sorpresa hacia falsos negativos. Que el AU exista y sea geoméricamente medible está respaldado; el umbral numérico concreto (0.10, $\times 10.0$) es heurístico, igual que el resto de las ~30 constantes geométricas de este archivo — pendiente de calibración contra DISFA (Fase 3). Ekman et al. (2002)
Umbral EAR de parpadeo action_units.py:88, 428-452	0.20, promedio de 2 pares verticales por ojo	VALIDADO	Corregido (Fase 1.1): el umbral canónico publicado es 0.20 (antes 0.15), y la fórmula EAR ahora promedia dos pares verticales de landmarks por ojo como especifica Soukupová & Čech, en vez de un solo par. Soukupová et al. (2016)
Normalización de blink_rate action_units.py:442-483	$\text{clip}((\text{bpm} - \text{ancla}) / 25, 0, 1)$; ancla = basal del sujeto o 26 ppm	VALIDADO	Corregido (Fase 1.2): el ancla ya no asume tasa de reposo (15-17 ppm). Usa 26 ppm (norma conversacional, Bentivoglio et al.) como respaldo antes de calibrar, y el basal propio del sujeto (medido durante los 30s de calibración) en cuanto está disponible — la normalización intra-sujeto que el rango individual amplio (4-48 ppm) exige. Bentivoglio et al. (1997); Maffei et al. (2025)

Constante / Ubicación	Valor	Nivel	Notas y fuentes
Cortes de blink_score congruence.py:262-269	0.3 / 0.6 / 0.8 → 80/90/60/30	HEURISTICO	La dirección del efecto (más ansiedad → más parpadeo) está respaldada, pero ni los puntos de corte ni los puntajes asignados provienen de ninguna fuente. Además, el rango de referencia individual es muy amplio (4–48 ppm), lo que exige normalización intra-sujeto, no cortes absolutos. Bentivoglio et al. (1997)
Coeficientes CHROM (3R–2G, 1.5R+G–1.5B) heart_rate.py:547-548	3.0 / 2.0 / 1.5	VALIDADO	Reproducen exactamente las ecuaciones publicadas. Sin cambios pendientes. de Haan et al. (2013)
Banda de frecuencia EVM config.py:81-85	0.7–3.0 Hz (42–180 BPM)	VALIDADO	Ampliada (Fase 1.6) de 0.8–2.0 Hz (48–120 BPM) a 0.7–3.0 Hz para cubrir taquicardia situacional en entrevistas, dentro del rango habitual de la literatura rPPG. Wu et al. (2012); de Haan et al. (2013)
Banda del estimador rPPG en vivo heart_rate.py:58-59	0.7–2.5 Hz (42–150 BPM)	HEURISTICO	Ojo: la entrada anterior ('Banda de frecuencia EVM') es la del renderizador offline en config.py; ésta es la del estimador que produce el BPM que ve el entrevistador, que usaba sus propios valores por defecto (0.7–4.0 Hz = 42–240 BPM) y no estaba registrada. Se estrechó el techo a 2.5 Hz tras medir que, con ruido de webcam, el pico del pulso deja de dominar el espectro y el argmax se iba a picos de ruido repartidos por toda la banda, produciendo lecturas de 190–220 BPM (inalcanzables sentado) y un rango mostrado de hasta 169 BPM para un pulso real de 72. El piso de 0.7 Hz es el habitual en la literatura rPPG; el techo de 2.5 Hz es una decisión de dominio (sujeto sentado en entrevista), ajustada en simulación sintética, no contra ground truth humano — de ahí el nivel heurístico. Ensancharla reintroduce el síntoma. de Haan et al. (2013)
Ventana mínima de estimación rPPG heart_rate.py:62, 734-754	8 s de span temporal; FFT con ventana Hann y zero-padding 4×	HEURISTICO	La necesidad de una ventana larga no es opinable: la resolución del FFT es f_s/n , así que con los 3 s que se exigían antes (a 20 FPS) el BPM reportado sólo podía caer en 60, 80, 100 ... — saltos de 20 BPM medidos, y con pulso real de 72 devolvía 80. Ahora se exige el span medido por timestamps (no un conteo de frames, para que valga a cualquier FPS real), y el zero-padding 4× interpola la rejilla espectral para quitar esa cuantización. El valor 8 s es un compromiso entre resolución y latencia de la primera lectura; la literatura rPPG usa ventanas de 10–30 s. Además el FFT ya no se aplica sobre la señal filtrada con Butterworth: la respuesta del propio filtro tiene un máximo dentro de la banda y sesgaba los espectros de ruido hacia un pico repetible de ~105 BPM, indistinguible de un pulso real. El enmascaramiento de banda del FFT cumple la función sin introducir ese sesgo. de Haan et al. (2013)

Constante / Ubicación	Valor	Nivel	Notas y fuentes
Umbral de confianza espectral (min_confidence) heart_rate.py:63, 783	0.40 (fracción de potencia en banda dentro de ± 0.2 Hz del pico)	HEURISTICO	Antes no había ningún filtro: cualquier estimación con bpm > 0 entraba al historial con el mismo peso que una lectura buena, que es lo que permitía que un pico de ruido se mostrara como pulso. La forma de la métrica sigue la SNR de de Haan & Jeanne (potencia del fundamental frente al resto de la banda) y se define sobre una vecindad en Hz, no en bins, para que no cambie con el zero-padding. El umbral 0.40 se eligió midiendo la distribución en simulación: señal buena da 0.65–0.94, ruido sin pulso da ~0.36. No está calibrado contra registros humanos con ECG de referencia, que es lo que haría falta para subirlo de nivel. de Haan et al. (2013)
Consistencia del pico entre ventanas heart_rate.py:66-67, 349-364	IQR $\leq$ 12 BPM sobre 20 estimaciones espaciadas 0.5 s	HEURISTICO	Necesario porque el umbral de confianza solo no separa un pulso débil del ruido estructurado: con ruido alto ambos puntúan ~0.38. Lo que sí los separa es la repetición — un pulso real pone el pico en la misma frecuencia ventana tras ventana. Sin este criterio, el ruido fuerte producía una lectura estable pero equivocada (~105 BPM para un pulso real de 72), que es peor que una oscilante porque parece confiable. Las estimaciones se espacian 0.5 s a propósito: calculadas por frame, ventanas consecutivas comparten ~95% de las muestras y su acuerdo mide el solape, no el pulso (medido: con estimación por frame el criterio dejaba pasar el 35% de las lecturas falsas; espaciadas, baja al 1–29%). Ni el IQR de 12 BPM ni el intervalo de 0.5 s provienen de ninguna fuente.
Límite de cambio fisiológico del BPM heart_rate.py:64, 366-381	8 BPM por segundo	HEURISTICO	La dirección tiene respaldo fisiológico obvio (el ritmo cardíaco no se mueve 60 BPM en un segundo, así que un salto así es artefacto de estimación, no medición), pero el valor concreto de 8 BPM/s no proviene de ninguna fuente. Actúa junto a la mediana de las últimas ~10 estimaciones: una lectura espuria aislada que supere el filtro de confianza queda amortiguada en vez de desplazar el valor mostrado.
Umbral de movimiento (motion_threshold) heart_rate.py:61	15.0 (píxeles normalizados por diagonal de frame)	HEURISTICO	Corregido de 5.0 a 15.0 tras diagnosticar que el valor anterior descartaba casi todos los frames: a 640×480 el umbral raw era de solo ~4 px, por debajo del jitter propio de los landmarks de MediaPipe en reposo (~2-5 px), así que el buffer nunca se llenaba y el BPM quedaba fijo en 0. No existe un valor publicado para este umbral — 15.0 es una estimación empírica con margen sobre el jitter conocido, pendiente de validar contra grabaciones con movimiento real etiquetado.

Constante / Ubicación	Valor	Nivel	Notas y fuentes
EMA de deriva del ROI de referencia nasal heart_rate.py:174-186	alpha = 0.01	HEURISTICO	Corrige un bug distinto del umbral de movimiento: el código restaba el valor RGB crudo del puente nasal al de la frente para cancelar ruido de iluminación, lo que con frecuencia daba medias negativas y disparaba la guarda de _compute_chrom_signal (BPM atascado en 0). Ahora se resta solo la deriva del ROI de referencia respecto a su propio basal (EMA con alpha=0.01), preservando el nivel absoluto de brillo de la frente que CHROM necesita. El valor de alpha es una elección empírica sin fuente publicada.
Indicador de estrés fisiológico heart_rate.py:856	clip((BPM medio - 70) / 50, 0, 1)	HEURISTICO	Antes era hr_stress*0.6 + variability_stress*0.4, con pesos elegidos por prueba y error. Se eliminó el término de variabilidad, que puntuaba la desviación estándar de este mismo historial de BPM como si fuera HRV: la HRV real exige intervalos R-R latido a latido, mientras que este historial contiene estimaciones espectrales de ventanas solapadas, así que su dispersión mide ruido del estimador. Con la regla 'poca variabilidad = estrés', eso premiaba con 'relajado' justamente a la señal de cámara mala (que produce estimaciones erráticas) y, tras suavizar la salida de BPM, habría quedado clavado en estrés máximo. Queda sólo el nivel de HR, cuya dirección (HR elevado acompaña activación simpática) sí tiene respaldo; los cortes 70/120 siguen sin fuente.
'nervousness' / 'confidence' fuera de la emoción dominante emotion_classifier.py: _apply_hysteresis, _merge_cnn_with_derived	se calculan y se muestran, pero no pueden ganar el argmax	HEURISTICO	Fase 2: estas dos etiquetas no existen en ningún dataset FER público ni tienen prototipo EMFACS; son una combinación propia de blendshapes elegida por prueba y error. Antes competían de igual a igual con las 7 clases del CNN entrenado y podían reservar hasta el 50% de la masa de probabilidad, de modo que la interfaz presentaba una heurística sin fuente y una predicción validada como si tuvieran el mismo respaldo. Ahora siguen reportándose —eliminarlas rompería código que depende de esas etiquetas— pero no pueden ser la emoción dominante. Medido contra el vídeo etiquetado de RAVDESS, el cambio subió el acierto de 50% a 64%: 'confidence' se estaba llevando un segmento de ira y otro de miedo. La corrección era exigible por honestidad y además resultó más exacta. Barrett et al. (2019)

Constante / Ubicación	Valor	Nivel	Notas y fuentes
Alcance real del reconocimiento de emoción emotion_classifier.py (todo el clasificador)	36% sobre 20 actores; solo 'happy' se sostiene (95%)	HEURISTICO	Medición del 2026-09-16 sobre 220 clips de CREMA-D (20 actores, ODbL). Con un único actor de RAVDESS el sistema puntuaba 46-54%; con 20 caras distintas cae al 36%. Por clase el deterioro es mayor que esa cifra: 'disgust' pasa de 88% a 15% y 'angry' de 62% a 22%, es decir que estaban ajustados a una cara concreta, no funcionando en general. El dato más relevante es la dispersión entre sujetos: del 9% en el peor actor al 73% en el mejor. La herramienta funciona bien con algunas personas y es inútil con otras, algo que una evaluación de un solo sujeto no puede detectar. Sólo 'happy' aguanta (95% aquí, 100% en RAVDESS). Diferencia por sexo: 40% en mujeres frente a 30% en hombres, no concluyente con esta muestra pero a vigilar, porque el sesgo demográfico en reconocimiento facial está documentado y esta herramienta interviene en contrataciones. La diferencia de resolución entre ambos conjuntos (480x360 frente a 1280x720) se descartó como explicación: evaluar los mismos clips de RAVDESS reducidos a 480x360 da 64% frente al 59% original, o sea que bajar resolución no perjudica —coherente con que el modelo se entrenó sobre imágenes de 48x48— y la caída al 36% se debe íntegramente a cambiar de persona. Queda un matiz a favor del sistema: los clips son demasiado cortos para calibrar el basal por sujeto que sí existe en una sesión real, de modo que el uso en vivo debería quedar por encima de este 36%. Reproducible con data/test_videos/evaluate_cremad.py y evaluate_resolution.py. Barrett et al. (2019)
Pesos del score de congruencia config.py:64-67	0.30 / 0.35 / 0.20 / 0.15	HEURISTICO	No existe ni puede existir una fuente para estos pesos: no hay ningún dataset público etiquetado con 'congruencia verdadera' contra el cual ajustarlos. Sólo pueden derivarse contra un proxy medible (p. ej. ansiedad auto-reportada con STAI) o declararse explícitamente como heurísticos. Barrett et al. (2019); Bond et al. (2006)
Cortes alto/moderado/bajo congruence.py:131-136	≥80 alto, ≥50 moderado, <50 bajo	HEURISTICO	Sin fuente. Definen la semántica visible (verde/amarillo/rojo) que el entrevistador interpreta, por lo que son las constantes de mayor consecuencia práctica de todo el sistema.
Penalización por desviación del baseline congruence.py:247	score = 100 – desviación × 160	HEURISTICO	El multiplicador 160 no tiene fuente. Más grave: la premisa de que desviarse del basal indica ocultamiento es la del Comparison Question Technique del polígrafo, que el NRC evaluó como de base científica débil y tasa de error desconocida. National Research Council et al. (2003)

Constante / Ubicación	Valor	Nivel	Notas y fuentes
Penalización por micro-expresiones contradictorias congruence.py:221	$100 - \text{ratio} \times 80 \times \text{relevancia}$	HEURISTICO	Sin fuente para el factor 80. La inferencia de 'enmascaramiento social' a partir de incongruencia AU↔emoción no está respaldada: Barrett et al. documentan que la relación entre configuración facial y estado interno es altamente variable entre personas, contextos y culturas. Barrett et al. (2019)
Pesos del relevance score micro_expressions.py:524-551	25 / 25 / 30 / 20 / 15	HEURISTICO	Sin fuente. El umbral de corte 60 tampoco la tiene.
Umbral de fricción del timeline interview_analyzer.py:92-93	nerviosismo +0.15, congruencia -10.0	HEURISTICO	Sin fuente. Disparan 'red flags' visibles en el reporte del candidato.
Constantes de normalización geométrica de AUs action_units.py:249-441 (~31 constantes, incl. AU5)	p. ej. $(\text{ratio} - 0.12) \times 8.0$	HEURISTICO	Ninguna proviene de la literatura: son factores de ajuste específicos de la malla de MediaPipe. No son 'ciencia' sino calibración, y sólo pueden fijarse ajustándolos contra intensidades AU codificadas por humanos certificados en FACS (DISFA aporta intensidad 0–5 para 12 AUs). Mavadati et al. (2013); Yan et al. (2014)

Qué no puede afirmar este sistema

Tres resultados de la literatura acotan directamente lo que EmotionLens puede sostener sobre una persona, y conviene tenerlos presentes al leer cualquier reporte que genere:

Bond et al. (2006)

Sobre 206 estudios y 24.483 jueces, la precisión humana para distinguir verdad de mentira es del 54%, apenas por encima del azar. Los meta-análisis no encuentran que las señales faciales se relacionen de forma fiable con la veracidad.

Barrett et al. (2019)

La correspondencia entre configuraciones faciales y estados emocionales internos es altamente variable entre personas, situaciones y culturas. Inferir la emoción de una persona a partir de su movimiento facial no está respaldado por la evidencia disponible.

National Research Council et al. (2003)

La base científica del Comparison Question Technique — comparar el comportamiento contra un basal propio para inferir ocultamiento — fue evaluada como débil, con tasa de error desconocida. El componente de 'desviación del baseline' de EmotionLens replica esa misma premisa.

En consecuencia, el score de congruencia debe entenderse como un **índice descriptivo de variabilidad expresiva**, no como una medida de honestidad, confiabilidad ni idoneidad laboral. Ninguna decisión de contratación debería apoyarse en él.