

Plan: migrar EmotionLens de prueba y error a evidencia científica

Objetivo: que ninguna constante que gobierne el comportamiento del sistema sea un número elegido a ojo. Cada una debe quedar en uno de tres estados — **VALIDADO** (valor publicado), **CALIBRADO** (ajustado contra un dataset con codificación FACS certificada) o **HEURÍSTICO** (sin respaldo, y mostrado como tal al usuario).

Estado de partida: **13 de 17 grupos de constantes carecen de respaldo publicado**. El inventario completo está en [backend/app/references.py](#) y se publica en [docs/bibliografia-cientifica.pdf](#).

Antes de la sesión de código: solicitar los datasets

La Fase 3 no puede empezar sin datos con codificación FACS hecha por humanos certificados. Los tres datasets relevantes se distribuyen bajo acuerdo académico y la aprobación tarda **días o semanas**. Conviene solicitarlos ya, aunque el código se escriba después.

Dataset	Qué aporta	Institución
DISFA	Intensidad AU 0–5, frame a frame, 27 sujetos — es el que permite calibrar la geometría de AUs	University of Denver (Mohammad Mahoor)
CASME II	247 micro-expresiones a 200 fps con etiquetas AU — valida la capa temporal	Chinese Academy of Sciences (Xiaolan Fu)
SAMM	159 micro-movimientos a 200 fps, 7 categorías — conjunto de prueba independiente	Manchester Metropolitan University (Moi Hoon Yap)

DISFA es el más importante: sin intensidades AU etiquetadas no hay forma de fijar las ~30 constantes de `action_units.py`.

Fase 0 — Infraestructura de procedencia ✓ hecha

- [backend/app/references.py](#) — registro de bibliografía + inventario de constantes.
- [backend/scripts/generate_bibliography.py](#) — genera el PDF desde el registro.
- [docs/bibliografia-cientifica.pdf](#) — 15 referencias verificadas con DOI.

El PDF se genera **desde el código**, así que no puede desincronizarse. Regla que adoptamos: ninguna constante nueva entra sin su entrada en el registro.

```
python -m backend.scripts.generate_bibliography
```

Fase 1 — Correcciones directas contra la literatura

No requiere datasets. Son casos donde existe un valor publicado y el código usa otro.

1.1 Umbral de parpadeo (EAR)

`action_units.py:88` usa 0.15; Soukupová & Čech (2016) publican 0.20. Además la fórmula EAR estándar promedia **dos** pares verticales de landmarks y el código usa uno solo. Corregir ambas cosas.

1.2 Ancla de la tasa de parpadeo ← corrige un sesgo real

`action_units.py:466` normaliza con $(bpm - 15) / 25$, es decir contra la tasa de **reposo**. Bentivoglio et al. (1997) reportan ~17 ppm en reposo pero **~26 ppm en conversación**. Una entrevista es una conversación: hoy un candidato que parpadea con total normalidad se registra como "elevado", lo que baja su score fisiológico y por tanto su congruencia. Reanclar a la norma conversacional.

Además, el rango individual sano es enorme (4-48 ppm), así que lo correcto no es un corte absoluto sino normalizar contra el propio basal del sujeto medido durante la calibración.

1.3 Prototipos AU→emoción incompletos

`MICRO_EXPR_PATTERNS` (`micro_expressions.py:54-90`) no coincide con los prototipos EMFACS publicados:

Emoción	EMFACS	En el código	Falta
Miedo	1+2+4+5+7+20+25/26	req 1,4 / sup 2,20,25	AU5
Ira	4+5+7+23	req 4,7 / sup 23,24	AU5
Sorpresa	1+2+5+26	req 2,25 / sup 26	AU1, AU5
Tristeza	1+4+15	req 1,15 / sup 17	AU4
Asco	9+15+16 (+6,11,17)	req 9 / sup 15,25	AU25 sobra
Desprecio	12+14 unilateral	igual	—

La categoría "stress" (AU23+AU24) **no es un prototipo EMFACS**: es invención del proyecto. O se elimina, o se marca explícitamente como heurística.

1.4 Implementar AU5 (Upper Lid Raiser)

`action_units.py` calcula 16 AUs pero **no AU5**, que aparece en 3 de los 6 prototipos de emoción básica. Su ausencia sesga miedo, ira y sorpresa hacia falsos negativos. Es geométricamente calculable desde la malla (apertura del párpado superior respecto al iris).

1.5 Ventana de duración modal

La bonificación de "duración óptima" usa 100-250 ms; Yan et al. (2013) sitúan la moda en **80-200 ms**. Ajuste menor, pero citable.

1.6 Banda rPPG

0.8–2.0 Hz (48–120 BPM) es correcta pero estrecha para entrevistas con estrés situacional. Evaluar 0.7–3.0 Hz (42–180 BPM), que es lo habitual en la literatura rPPG.

Fase 2 — Reencuadre de afirmaciones

Aquí no se cambian números sino lo que el sistema **dice** sobre una persona. Tres resultados de la literatura acotan lo defendible:

- **Bond & DePaulo (2006)**: sobre 24.483 jueces, la precisión humana para detectar mentiras es 54%. Los meta-análisis no hallan relación fiable entre señales faciales y veracidad.
- **Barrett et al. (2019)**: la correspondencia entre configuración facial y estado interno es altamente variable entre personas, contextos y culturas.
- **NRC (2003)**: la premisa "desviarse del basal indica ocultamiento" es la del polígrafo (CQT), evaluada como de base científica débil y tasa de error desconocida.

Acciones:

- 1 Renombrar el concepto de "**Trustworthiness / Confiabilidad**" a algo descriptivo y defendible: índice de variabilidad expresiva. El sistema mide variabilidad, no honestidad.
 - 2 Quitar de [congruence.py:224-248](#) la inferencia de "possible concealment". Medir y reportar la desviación como dato descriptivo, sin interpretarla.
 - 3 Revisar [interview_analyzer.py](#): "[social_masking](#)" y [red_flags](#) afirman más de lo que la evidencia permite. Reformular como observaciones, no como banderas.
 - 4 Que el reporte PDF marque visualmente cada métrica con su nivel de evidencia, para que un entrevistador no confunda un compuesto heurístico con una medición.
-

Fase 3 — Calibración empírica (requiere los datasets y tu GPU)

3.1 Geometría de AUs contra DISFA

Las ~30 constantes de [action_units.py](#) ($(ratio - 0.12) * 8.0$ y similares) no son ciencia: son factores de ajuste de la malla de MediaPipe. Procedimiento:

- 1 Correr el analizador sobre los videos de DISFA.
- 2 Para cada AU, regresión entre el valor geométrico crudo y la intensidad 0–5 codificada por humanos.
- 3 Sustituir cada constante por los coeficientes ajustados.
- 4 Reportar correlación (ICC / Pearson) por AU — y marcar como **HEURÍSTICO** todo AU cuya correlación quede baja, en vez de fingir que está calibrado.

Esto convierte ~30 constantes de HEURÍSTICO a CALIBRADO, con error medido.

3.2 Capa temporal contra CASME II, prueba en SAMM

Calibrar umbrales de detección (`onset_ratio > 2.0`, `threshold + var * 2.5`, `min_detection_gap`) maximizando F1 contra las micro-expresiones etiquetadas de CASME II. Evaluar en SAMM **sin reajustar**, para tener una cifra honesta de generalización.

3.3 El score de congruencia — decisión de producto pendiente

Los pesos 0.30/0.35/0.20/0.15 y los cortes 80/50 **no pueden validarse contra la literatura**, porque no existe ningún dataset etiquetado con "congruencia verdadera". No es que falte buscar la cita: la cita no puede existir. Hay tres salidas honestas, y hay que elegir una:

Opción	Qué implica
A. Derivar contra un proxy medible	Ajustar los pesos para predecir algo que sí se puede medir (p. ej. ansiedad auto-reportada con STAI antes/después). Requiere recolectar datos con consentimiento. Es lo más riguroso.
B. Declarar heurístico y hacerlo ajustable	Mantener el score, exponer los pesos en la UI y etiquetarlo visiblemente como heurístico. Rápido y honesto, pero el número sigue sin significar nada verificable.
C. Eliminar el compuesto	Mostrar los 4 componentes por separado sin fusionarlos. Se pierde el "gauge" del dashboard, se gana que todo lo mostrado es medible.

Mi recomendación es **C para el reporte y B para el dashboard en vivo**: el número único es útil como señal de atención durante la entrevista, pero no debería quedar impreso en un documento que alguien use para decidir una contratación.

Fase 4 — Validación

- Tests de regresión que fijen los valores calibrados y fallen si alguien los toca sin actualizar el registro de procedencia.
- Test que verifique que toda constante en `config.py` tiene entrada en `references.py` — así la regla se hace cumplir sola.
- Reportar en el README las métricas reales de acuerdo con ground truth por AU, en lugar de la tabla de efectividad actual, que no está medida.

Fase 5 — Regenerar documentación

Volver a correr el generador (el PDF refleja automáticamente los nuevos niveles) y actualizar el README con: qué está calibrado, contra qué dataset, con qué error, y qué sigue siendo heurístico.

Orden sugerido en la sesión

- 1 Fase 1 completa — son correcciones directas, bajo riesgo, alto valor (1.2 corrige un sesgo que hoy perjudica a candidatos normales).
- 2 Fase 2 — decidir el reencuadre contigo, porque cambia qué es el producto.
- 3 Fase 3 sólo cuando lleguen los datasets.

Las Fases 1 y 2 no dependen de nada externo: se pueden hacer completas en una sesión.